SeismicAI Pulse: a próxima semana, área por área

Uma startup acadêmica que transforma o catálogo público de terremotos em um mapa semanal de probabilidades para o Círculo de Fogo do Pacífico

Alice De Muylder, Valmir Cerutti e Tiago Abreu — Disciplina de Redes Neurais e Deep Learning, 2026. Código, dados e protótipo: repositório do projeto; site: https://deep-learning-terremoto.web.app

1. Problema

Terremotos não podem ser previstos no sentido estrito — ninguém sabe dizer o dia, o lugar exato e a magnitude do próximo. Mas a sismicidade está longe de ser aleatória. Ela se concentra em regiões conhecidas, como o Círculo de Fogo do Pacífico, onde ocorrem três de cada quatro terremotos de magnitude 4 ou mais do planeta, e se agrupa no tempo: um evento grande costuma ser seguido por semanas de réplicas, e a atividade tende a se espalhar para áreas vizinhas.

Hoje, quem precisa lidar com esse risco encontra duas fontes de informação: catálogos de eventos, que dizem o que já aconteceu, e mapas de risco sísmico, que trabalham na escala de décadas. Falta o meio do caminho — uma visão simples, de curto prazo e por área, que responda a uma pergunta prática: **nesta semana, em quais regiões a atenção deve estar?** É uma pergunta relevante para seguradoras e resseguradoras, que acompanham a exposição de curto prazo das carteiras; para a defesa civil e para operadores de infraestrutura crítica — portos, usinas, mineração —, que precisam priorizar inspeções e prontidão; e para o jornalismo científico.

2. Solução proposta

O SeismicAI Pulse divide o Círculo de Fogo em 709 células de 2° × 2° (cerca de 220 km de lado) e, para cada uma, estima toda semana a **probabilidade de ocorrer pelo menos um terremoto de magnitude ≥ 4,0 na semana seguinte**. A estimativa vem de uma rede neural treinada com o histórico das 52 semanas anteriores da célula e de suas oito vizinhas. Uma segunda rede, de Hopfield, resume essa probabilidade e a atividade recente em um estado de alerta — NORMAL, ATENÇÃO ou ALARME —, em que o alarme é reservado a padrões associados a terremotos de magnitude mais alta (≥ 5,0).

O resultado é publicado em um site com um mapa interativo, atualizado a partir do feed público do USGS. O produto não prevê terremotos: ele mede, com probabilidades calibradas, onde a atividade sísmica de curto prazo está mais provável, e diz isso de forma que qualquer pessoa possa ler.

3. Dados

A fonte é o catálogo ComCat do United States Geological Survey (USGS), acessado pelo serviço FDSN Event Web Service. Foram baixados todos os eventos de magnitude ≥ 4,0 registrados no mundo entre janeiro de 2000 e dezembro de 2025 — 358.672 eventos, dos quais 73,8 % dentro das doze caixas que delimitam o Círculo de Fogo. O período começa em 2000 porque a rede sismográfica global já estava consolidada; antes disso, muitos eventos de magnitude 4 em áreas remotas simplesmente não eram registrados, e a rede neural aprenderia uma "queda de atividade" que é só falha de medição.

A preparação seguiu critérios explícitos: apenas registros do tipo *earthquake* (sem explosões ou erupções), sem duplicatas, sem valores faltantes de tempo, posição, profundidade ou magnitude. Cada evento foi atribuído a uma célula e a uma semana (segunda a domingo, em UTC). Para cada célula e semana foram calculadas dez variáveis — número de eventos, magnitude máxima e média, energia sísmica liberada, profundidade média, eventos de magnitude ≥ 5 e ≥ 6, semanas desde o último evento e a atividade nas células vizinhas —, além de cinco atributos fixos da célula, como sua posição e sua taxa histórica de

atividade. A amostra é o par (célula, semana): 629.592 pares para treino (2001–2017), 111.313 para validação (2018–2020) e 184.340 para teste (2021–2025). A divisão é temporal, e tudo que o modelo "sabe" sobre uma célula vem exclusivamente do período de treino, o que evita qualquer vazamento de informação do futuro.

Os picos que aparecem nas séries semanais — 59 eventos em uma semana na célula do Mar de Banda, em novembro de 2023 — são sequências de réplicas de terremotos rasos (naquele caso, um dubleto M7,1), não erros: em 5.914 sequências do catálogo, o número de réplicas é explicado pela magnitude e pela profundidade do evento principal, e as leis de Omori e de Båth se reproduzem. Não há, em contrapartida, sinal de ciclo: a espera desde o terremoto anterior não prevê a magnitude do próximo, e os intervalos entre eventos principais seguem um processo de Poisson. Esse agrupamento de curto prazo — e só ele — é o sinal que o modelo aprende.

Um diagnóstico de completude, baseado na lei de Gutenberg–Richter, mostrou que a detecção de eventos pequenos melhorou ao longo do período, sobretudo na Indonésia. Esse efeito explica a subida gradual da fração de semanas com atividade (de 14,5 % no treino para 16,6 % no teste) e é tratado no artigo como uma limitação declarada, não como um aumento real da sismicidade.

4. Inteligência Artificial

O problema é de classificação binária probabilística sobre séries temporais, com classes desbalanceadas: só uma em cada seis amostras é positiva. Por isso as métricas principais são a área sob a curva precision-recall (PR-AUC), a ROC-AUC e a calibração das probabilidades — a acurácia engana, já que "dizer sempre não" acerta 84 % das vezes.

Antes das redes, quatro baselines estatísticos: persistência (houve evento esta semana → haverá na próxima), climatologia (a taxa histórica da célula), taxa recente (a fração das últimas 52 semanas com evento) e a média das duas últimas, o "combinado", que foi a meta a superar: ROC-AUC 0,836 e PR-AUC 0,552 no teste.

A arquitetura principal é uma **LSTM**, uma rede recorrente que lê a sequência de 52 semanas mantendo um estado interno e combina o estado final com os atributos fixos da célula antes de produzir a probabilidade (24 mil parâmetros). Foi escolhida porque os dados são uma série temporal e a hipótese central do projeto é temporal: a atividade recente muda a probabilidade da semana seguinte. Para isolar o valor da recorrência, duas MLPs foram treinadas como comparação: uma sobre as mesmas entradas da LSTM achatadas e outra sobre 45 resumos da sequência em janelas de 1, 4, 12 e 52 semanas. Todas foram treinadas com entropia cruzada sem ponderação — uma escolha deliberada para que as probabilidades saíssem calibradas —, otimizador Adam e parada antecipada pela PR-AUC de validação.

Duas outras redes completam o sistema. Uma **Máquina de Boltzmann Restrita (RBM)**, treinada sem nenhum rótulo por divergência contrastiva, serviu para investigar o que se aprende da distribuição das features por si só: sua energia livre mede quão "atípica" é uma semana. E uma **rede de Hopfield** é a camada de saída: uma memória associativa que guarda três protótipos (NORMAL, ATENÇÃO, ALARME) e relaxa um vetor de 26 bits — limiares sobre a probabilidade da LSTM, sobre a atividade recente e sobre a magnitude máxima — até o estado mais próximo. O alarme só é emitido quando a rede converge para o protótipo de ALARME, aprendido a partir das semanas que antecederam terremotos de magnitude ≥ 5.

5. Resultados

Modelo	ROC-AUC	PR-AUC	Brier	Precisão no top 5 %
Persistência	0,646	0,266	0,196	31 %
Climatologia (taxa histórica)	0,830	0,528	0,107	71 %
Combinado (meta da Fase 1)	0,836	0,552	0,103	74 %
Regressão logística	0,839	0,565	0,102	76 %
RBM (energia livre, sem rótulos)	0,792	0,402	0,117	50 %
MLP (janelas)	0,841	0,569	0,101	76 %
LSTM	**0,841**	**0,571**	**0,101**	**76 %**

Tabela 1 — Desempenho no conjunto de teste (2021–2025). Brier: erro quadrático médio das probabilidades (menor é melhor).

A LSTM superou a meta em todas as métricas, com desempenho estável nos cinco anos do teste. Na forma como o produto é usado — sinalizar a cada semana as 5 % células mais prováveis —, 76 % delas têm de fato um terremoto M ≥ 4 na semana seguinte. As probabilidades são confiáveis: quando o modelo diz 83 %, o evento ocorre em 84 % dos casos; quando diz 59 %, em 62 %. A climatologia, nas mesmas células, diria 60 % onde se observa 84 % — ela não enxerga as sequências em curso.

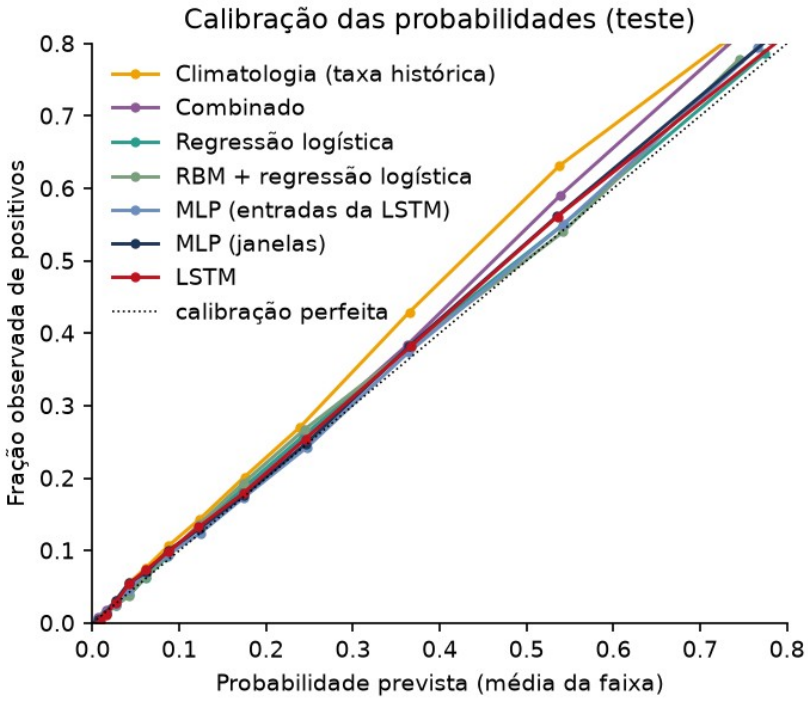


Figura 1 — Calibração das probabilidades no teste.

É exatamente nessas sequências que a rede ganha. Separando o teste por situação, a PR-AUC da LSTM supera a da climatologia em +0,071 nas semanas em que a célula teve um M ≥ 5 recente (0,682 → 0,753), em +0,044 quando o evento grande foi nas células vizinhas e, nas células historicamente quietas, quase triplica (0,025 → 0,068). A hipótese do agrupamento temporal e a do contágio espacial se confirmam.

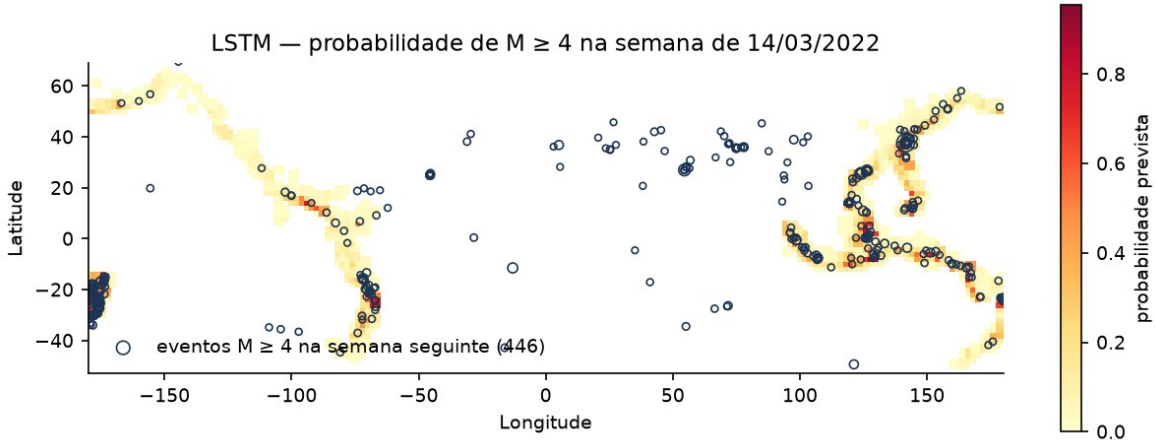


Figura 2 — Probabilidades da LSTM e eventos ocorridos na semana de 14 de março de 2022.

Dois achados merecem destaque. O primeiro é que a MLP sobre janelas agregadas empata com a LSTM (0,841 / 0,569): a informação temporal útil está em estatísticas simples da sequência — quantos eventos, há quanto tempo —, e a recorrência não encontra estrutura além disso. O segundo vem da análise de importância: a taxa histórica da célula vale cerca de dez vezes mais que a atividade recente. Em outras palavras, *onde* explica a maior parte do problema; a rede acrescenta o *quando*, e o acrescenta nas horas certas.

Testamos também se faltavam variáveis: 22 novas — memória de dois e cinco anos, anel de 5 × 5 células, resolução diária, uma taxa de réplicas tipo ETAS e proxies de composição — movem a ROC-AUC em 0,001, e sozinhas recuperam 99 % do desempenho das originais. O teto está na informação do catálogo, não nas variáveis nem na arquitetura.

A RBM, sem ver um único rótulo, atinge ROC-AUC 0,792 só com a energia livre — o modelo descobre sozinho que semana atípica é semana de risco. A rede de Hopfield entrega estados legíveis (o protótipo de ALARME acende exatamente os bits de magnitude ≥ 5 recente) e emite alarme em 11 % das células, com precisão 2,4 vezes a taxa base; um limiar simples sobre a probabilidade calibrada, no mesmo ponto de operação, faz melhor, o que mostra que o valor da Hopfield está na interpretabilidade da saída, não na discriminação.

6. Produto

O modelo virou protótipo em duas frentes. A primeira é um site público hospedado no Firebase: um motor de inferência em Python baixa os eventos novos do feed do USGS, calcula as features da última semana completa com o mesmo código usado no treino, aplica a LSTM e a rede de Hopfield e grava um documento por semana no Cloud Firestore. O site lê esse documento e desenha o mapa do Pacífico: cada célula colorida pela probabilidade e contornada pelo estado de alerta, com seletor de semana (a semana corrente e as semanas do teste, nas quais é possível ver, sobre o mapa, o que de fato aconteceu), ranking das áreas mais prováveis, detalhe por célula e as métricas do modelo. A segunda frente é um aplicativo Streamlit com a mesma visão para uso local, com histórico de dois anos por célula.

O motor de inferência foi verificado contra as predições gravadas no treino: a diferença máxima é de um bilionésimo. O que o usuário vê é exatamente o modelo que foi avaliado.

7. Limitações

Os ganhos sobre a taxa histórica são reais, mas pequenos — décimos de ponto de ROC-AUC. A maior parte da informação é geográfica. O catálogo tem completude variável no espaço e no tempo e mistura tipos de

magnitude diferentes. Células de 2° e semanas são grosseiras, e um terremoto grande sem precursores no catálogo não tem padrão reconhecível: um em cada quatro eventos M ≥ 5 do teste chegou sem nenhuma assinatura recente na célula ou nos vizinhos. Não há física de falhas no modelo, só estatística. E, acima de tudo: o SeismicAI Pulse tem finalidade acadêmica e experimental. Seus resultados são estimativas produzidas a partir dos dados e das hipóteses do projeto; ele não é um sistema oficial de alerta, não faz previsão determinística de terremotos e não substitui as instituições responsáveis pelo monitoramento sísmico.

8. Próximos passos

Refinar a grade para 1° e o horizonte para três dias, de modo a capturar as réplicas mais cedo; tratar a completude por segmento, começando mais tarde onde o catálogo é incompleto; prever também o número esperado de eventos, uma tarefa em que a sequência tem mais a dizer e a LSTM teria um papel maior; comparar o modelo com o ETAS, o padrão da sismologia estatística para réplicas; e, no produto, agendar a publicação semanal e abrir uma API para que seguradoras e órgãos públicos consumam as probabilidades diretamente.

Referências

1. UNITED STATES GEOLOGICAL SURVEY (USGS). ComCat – Comprehensive Earthquake Catalog. https://earthquake.usgs.gov/data/comcat/. Acesso em 2026.
2. UNITED STATES GEOLOGICAL SURVEY (USGS). FDSN Event Web Service. https://earthquake.usgs.gov/fdsnws/event/1/. Acesso em 2026.
3. UNITED STATES GEOLOGICAL SURVEY (USGS). Real-time Earthquake Feeds. https://earthquake.usgs.gov/earthquakes/feed/. Acesso em 2026.
4. GUTENBERG, B.; RICHTER, C. F. Frequency of earthquakes in California. *Bulletin of the Seismological Society of America*, v. 34, n. 4, p. 185–188, 1944.
5. HOCHREITER, S.; SCHMIDHUBER, J. Long short-term memory. *Neural Computation*, v. 9, n. 8, p. 1735–1780, 1997.
6. HINTON, G. E. Training products of experts by minimizing contrastive divergence. *Neural Computation*, v. 14, n. 8, p. 1771–1800, 2002.
7. HOPFIELD, J. J. Neural networks and physical systems with emergent collective computational abilities. *Proceedings of the National Academy of Sciences*, v. 79, n. 8, p. 2554–2558, 1982.